



## รายงาน

### Fundamentals of Data Science

กิตติพงศ์ พวงศินธ์ 66070016

ชัชชัย แสงนิล 66070044

ยศกร ชูวงษ์ 66070168

ศุภณัฐ จันทรสาข 66070196

สิรภพ สรรค์ศิลा 66070204

วรรุฒิ มหาทอง 66070307

## เสนอ

อ.เฉลิมพล ศิริกายน

รายงานเล่มนี้เป็นส่วนหนึ่งของรายวิชา

### Fundamentals of Data Science

รหัสวิชา 06026208

คณะเทคโนโลยีสารสนเทศ

สาขาวิชาการข้อมูลและการวิเคราะห์เชิงธุรกิจ

สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

ภาคเรียนที่ 2 ปีการศึกษา 2567

สารบัญ

คำนำ.....

คำนำ.....

คำนำ.....

คำนำ.....

คำนำ.....

คำนำ.....

คำนำ.....

คำนำ.....

คำนำ

คำจำกัดความ

គំរាប់ពីថ្ងៃទី ០១ ខែ មិថុនា ឆ្នាំ ២០២៣ ដល់ពីថ្ងៃទី ០៩ ខែ មិថុនា ឆ្នាំ ២០២៣

គំរាប់ពីថ្ងៃទី ០១ ខែ មីនា ឆ្នាំ ២០២៣ ដល់ពីថ្ងៃទី ០៩ ខែ មីនា ឆ្នាំ ២០២៣

## คำนำ

รายงานฉบับนี้มีวัตถุประสงค์เพื่อวิเคราะห์ข้อมูลของผู้กระทำการรุนแรงในครอบครัว โดยมุ่งเน้นไปที่การทำความเข้าใจปัจจัยที่มีผลต่อสุขภาพจิตของบุคคลเหล่านี้ และการแบ่งกลุ่มประชากรออกเป็น Cluster ตามลักษณะพฤติกรรมและความเสี่ยงที่แตกต่างกัน เพื่อนำไปสู่การพัฒนาแนวทางแก้ไขปัญหาที่มีประสิทธิภาพมากยิ่งขึ้น

ความรุนแรงในครอบครัวเป็นปัญหาที่ซับซ้อนและส่งผลกระทบอย่างรุนแรงต่อผู้ถูกกระทำ รวมถึงผู้กระทำการด้วยการทำความเข้าใจปัจจัยที่เกี่ยวข้องกับสุขภาพจิตของผู้กระทำการรุนแรงจึงเป็นสิ่งสำคัญในการวางแผนการป้องกันและแก้ไขปัญหาอย่างยั่งยืน โดยรายงานนี้จะตอบคำถามสำคัญดังต่อไปนี้:

- ปัจจัยใดบ้างที่มีผลผลกระทบต่อสุขภาพจิตของผู้กระทำการรุนแรงมากที่สุด?
- สามารถแบ่งประชากรออกเป็นกลุ่มที่มีความเสี่ยงแตกต่างกันได้อย่างไร?
- Cluster ใดมีแนวโน้มสุขภาพจิตที่แย่ที่สุด และแต่ละ Cluster มีลักษณะพฤติกรรมที่แตกต่างกันอย่างไร?

ข้อมูลที่ใช้ในการวิเคราะห์ประกอบด้วยข้อมูล 564 ราย และ 19 คอลัมน์ ซึ่งครอบคลุมทั้งข้อมูลเชิงหมวดหมู่ เช่น ภูมิภาค จังหวัด เพศ และสถานภาพ และข้อมูลเชิงตัวเลข เช่น อายุ ระดับการศึกษา อาชญากรรม และระดับความโกรธ การวิเคราะห์ข้อมูลจะใช้เทคนิคทางสถิติและการเรียนรู้ของเครื่อง (Machine Learning) เพื่อระบุรูปแบบและความสัมพันธ์ที่ซ่อนอยู่ในข้อมูล

ผลการวิเคราะห์ที่ได้จากรายงานนี้ จะเป็นประโยชน์อย่างยิ่งต่อผู้ที่เกี่ยวข้องในการพัฒนาแนวทางแก้ไขปัญหาความรุนแรงในครอบครัว เช่น นักจิตวิทยา นักสังคมสงเคราะห์ ผู้กำหนดนโยบาย และองค์กรที่ทำงานด้านการช่วยเหลือผู้ที่ได้รับผลกระทบจากความรุนแรงในครอบครัว โดยสามารถนำไปใช้ในการพัฒนาโปรแกรมให้คำปรึกษา นโยบายสนับสนุน และโปรแกรมช่วยเหลือกลุ่มเสี่ยงต่างๆ ได้อย่างตรงจุดและมีประสิทธิภาพมากยิ่งขึ้น หวังเป็นอย่างยิ่งว่ารายงานฉบับนี้จะเป็นประโยชน์ต่อการทำความเข้าใจและแก้ไขปัญหาความรุนแรงในครอบครัวต่อไป

## 1. Business Understanding

### 1.1 วัตถุประสงค์

เพื่อศึกษาแนวโน้มการเกิดปัญหาความรุนแรงในครอบครัว โดยพิจารณาจากปัจจัยต่างๆ เช่น การใช้สารเสพติด การดื่มเครื่องดื่มมีน้ำ ความเครียดทางการเงิน ปัญหาทางสุขภาพจิต และความสัมพันธ์นั้น เป็นเหตุผลที่สำคัญและเกี่ยวข้องกับปัญหาทางสังคมที่ขึ้นชื่อน

### 1.2 สามารถนำไปใช้ทำอะไรได้บ้าง

- ระบุกลุ่มเสี่ยงและช่วยเหลือเชิงรุก: ข้อมูลจะช่วยให้สามารถระบุกลุ่มบุคคลที่มีความเสี่ยงต่อการกระทำความรุนแรงในครอบครัวได้แม่นยำยิ่งขึ้น ทำให้สามารถวางแผนและดำเนินการช่วยเหลือเชิงรุกได้อย่างมีประสิทธิภาพ เช่น การจัดโปรแกรมให้คำปรึกษาหรือการสนับสนุนเฉพาะกลุ่ม
- พัฒนาแนวทางป้องกันและแก้ไขปัญหา: ข้อมูลเชิงลึกเกี่ยวกับปัจจัยที่เกี่ยวข้องกับความรุนแรงในครอบครัวจะช่วยในการพัฒนาแนวทางป้องกันและแก้ไขปัญหาที่มีประสิทธิภาพมากยิ่งขึ้น เช่น การปรับปรุงนโยบาย การสร้างโปรแกรมการศึกษา หรือการฝึกอบรม
- นำเสนอข้อมูลเชิงลึกเกี่ยวกับปัจจัยที่เกี่ยวข้องกับความรุนแรงในครอบครัว: การวิเคราะห์ข้อมูลจะช่วยให้เข้าใจถึงปัจจัยที่ส่งผลต่อการเกิดความรุนแรงในครอบครัวได้อย่างลึกซึ้ง เช่น ปัจจัยทางเศรษฐกิจ สังคม จิตวิทยา หรือความสัมพันธ์ ทำให้สามารถวางแผนการแก้ไขปัญหาได้อย่างตรงจุด
- สร้างความตระหนักรู้และกระตุ้นให้สังคมร่วมมือกันแก้ไขปัญหา: การเผยแพร่ข้อมูลและผลการวิเคราะห์จะช่วยสร้างความตระหนักรู้เกี่ยวกับปัญหาความรุนแรงในครอบครัวในสังคม กระตุ้นให้เกิดการเปลี่ยนแปลงทัศนคติและพฤติกรรม และส่งเสริมให้สังคมร่วมมือกันแก้ไขปัญหาอย่างจริงจัง

### 1.3 คำถามที่ต้องตอบ

- ปัจจัยอะไรที่ส่งผลกระทบต่อสุขภาพจิตมากที่สุด
- เราสามารถแบ่งประชากรออกเป็นกลุ่มที่มีความเสี่ยงต่างกันได้หรือไม่?
- Cluster ในนี้มีแนวโน้มสุขภาพจิตแย่ที่สุด และแต่ละ Cluster มีลักษณะพฤติกรรมที่แตกต่างกันอย่างไร?

## 2. data Understanding

## 2.1 โครงสร้างของข้อมูล

- ข้อมูลเมืองทั้งหมด 564 ถัว และ 19 คอลัมน์
  - คอลัมน์ที่มีข้อมูลเชิงหมวดหมู่ (เช่น ภูมิภาค จังหวัด เพศ สถานภาพ เป็นต้น)
  - คอลัมน์ที่เป็นตัวเลข (เช่น อายุ ผลก่อสร้าง ความกว้าง เป็นต้น)

## 2.2 ข้อมูลเชิงหมวดหมู่

- Regional (ภูมิภาค) แบ่งออกเป็น 4 ภูมิภาค (ภาคกลางเป็นสัดส่วนมากที่สุด)
  - Province (จังหวัด) มี 69 จังหวัด (กรุงเทพฯ เป็นจังหวัดที่พบมากที่สุด)
  - Gender (เพศ) พบร่วมกันว่า ส่วนใหญ่เป็นเพศชาย (461 คน) รองลงมาคือเพศหญิงและไม่ระบุเพศ
  - Age Range (ช่วงอายุ)
    - วัยกลางคน (36-59 ปี) เป็นกลุ่มที่ถูกกระทำมากที่สุด (287 คน)
    - รองลงมาคือวัยผู้ใหญ่ต่อนั้น (19-35 ปี)

### 2.3 ข้อมูลเชิงตัวเลข

- Age (อายุ)
    - ค่าเฉลี่ย 40.2 ปี
    - ช่วงอายุที่พบมากสุดอยู่ในวัยกลางคน
  - Alcohol, Drug, Rage และปัจจัยอื่นๆ มีค่าเฉลี่ยต่ำ แต่มีค่าผิดปกติสูงมากในบางราย

## 2.4 ตารางข้อมูล

## 2.5 จำนวนแถวและคอลัมน์

```
df.shape
✓ 0.0s
(564, 19)
```

มีทั้งหมด 564 แถว 19 คอลัมน์

## 2.6 สำรวจว่ามีค่าว่างในข้อมูลหรือไม่

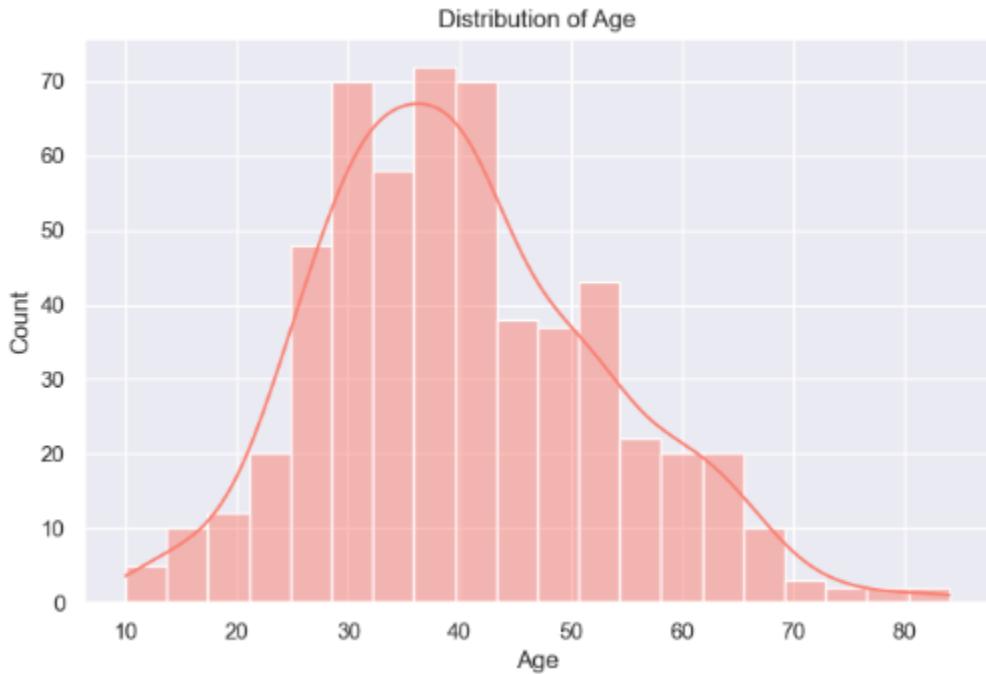
```
df.info()
✓ 0.0s
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 564 entries, 0 to 563
Data columns (total 19 columns):
 #   Column           Non-Null Count  Dtype  
--- 
 0   Regional        564 non-null    object  
 1   Province         564 non-null    object  
 2   District          564 non-null    object  
 3   Sub-District     564 non-null    object  
 4   Gender            564 non-null    object  
 5   Age               564 non-null    int64  
 6   Age Range         564 non-null    object  
 7   Relation          564 non-null    object  
 8   Mariage Registration 564 non-null  object  
 9   Alcohol           564 non-null    int64  
 10  Drug              564 non-null    int64  
 11  Authoritative     564 non-null    int64  
 12  Rage              564 non-null    int64  
 13  Jealous           564 non-null    int64  
 14  Divorce           564 non-null    int64  
 15  Health Problem    564 non-null    int64  
 16  Mental Problem    564 non-null    int64  
 17  Gambling Addict   564 non-null    int64  
 18  Economics Stress   564 non-null    int64  
dtypes: int64(11), object(8)
memory usage: 83.8+ KB
```

```
df.isna().sum()
✓ 0.0s
Regional          0
Province           0
District           0
Sub-District       0
Gender             0
Age                0
Age Range          0
Relation           0
Mariage Registration 0
Alcohol            0
Drug               0
Authoritative      0
Rage               0
Jealous            0
Divorce            0
Health Problem     0
Mental Problem     0
Gambling Addict    0
Economics Stress   0
dtype: int64
```

จาก df.isnull().sum() แล้วทุกคอลัมน์เป็น 0 แสดงว่า ข้อมูลไม่มีค่าว่าง

## 2.7 การกระจายตัวของอายุ



จากราฟ สามารถอธิบายการกระจายตัวของอายุได้ดังนี้

- ช่วงอายุที่มีความถี่สูงสุด: ช่วงอายุที่มีความถี่สูงสุด (mode) อยู่ในช่วงประมาณ 30-40 ปี ซึ่งแสดงว่ากลุ่มตัวอย่างส่วนใหญ่มีอายุอยู่ในช่วงนี้
- ช่วงอายุที่มีความถี่ต่ำ: ช่วงอายุที่มีความถี่ต่ำจะอยู่บริเวณส่วนปลายของกราฟ คือช่วงอายุ 10-20 ปี และช่วงอายุ 60-80 ปี
- การกระจายตัวโดยรวม: กราฟแสดงให้เห็นว่าการกระจายตัวของอายุมีความสมมาตร (symmetric) โดยประมาณ ซึ่งบ่งชี้ว่าข้อมูลมีการกระจายตัวอย่างสม่ำเสมอในแต่ละช่วงอายุ

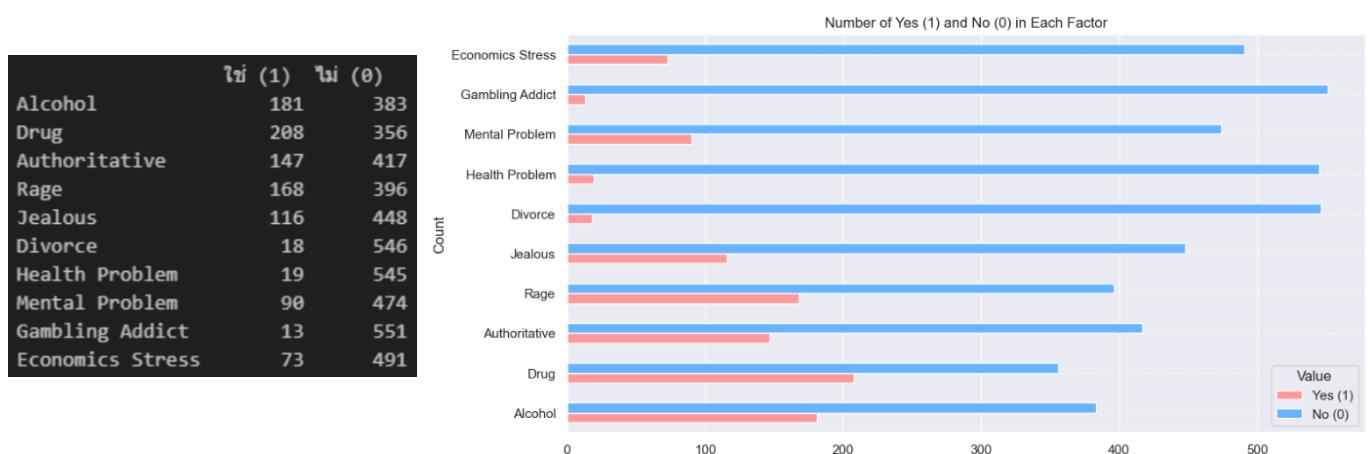
## 2.8 ข้อมูลสถิติพื้นฐาน เอพาร์ชุดข้อมูลที่ไม่ใช่ตัวเลข

df.describe(include=[ 'O'])									
	✓ 0.0s								
	Regional	Province	District	Sub-District	Gender	Age Range	Relation	Mariage Registration	
count	564	564	564	564	564	564	564	564	564
unique	4	69	303	453	3	5	4	5	
top	ภาคกลาง	กรุงเทพมหานคร	เมือง ราชบุรี	ในเมือง	ชาย	วัยกลางคน 36 - 59 ปี	สมรส	ไม่ร่วม	
freq	257	59	14	10	461	287	259	216	

จากการแสดงข้อมูลให้เห็นว่า

- ภาคที่มากที่สุดคือ ภาคกลาง
- จังหวัดที่มากที่สุดคือ กรุงเทพมหานคร
- เพศที่มากที่สุด คือ เพศชาย
- ช่วงอายุที่มากที่สุดคือ ช่วงวัยกลางคน 36-59 ปี
- สถานะที่มากที่สุดคือ สมรส

## 2.9 ข้อมูลสถิติของปัจจัยที่ส่งผลต่อการทำความรุนแรงในครอบครัว



### 3. Data Preparation

#### 3.1 นำปัจจัยที่ลักษณะคล้ายกันรวมกัน

The screenshot shows a Jupyter Notebook cell with Python code for data preparation. The code merges several columns into one, removes specific columns, and then displays a preview of the resulting DataFrame.

```
# สร้างฟังก์ชันเพื่อรวมคอลัมน์ที่เกี่ยวข้อง
pref_data["Substance Use"] = pref_data["Alcohol"] + pref_data["Drug"]
pref_data["Aggression"] = pref_data["Authoritative"] + pref_data["Rage"]
pref_data["Relationship issues"] = pref_data["Jealous"] + pref_data["Divorce"]
pref_data["Health Issues"] = pref_data["Health Problem"] + pref_data["Mental Problem"]
pref_data["Financial Issues"] = pref_data["Gambling Addict"] + pref_data["Economics Stress"]

# ลบคอลัมน์เดิมที่ถูกนำไปใช้แล้ว
pref_data.drop(columns=["Alcohol", "Drug", "Authoritative", "Rage", "Jealous", "Divorce",
                      "Health Problem", "Mental Problem", "Gambling Addict", "Economics Stress"], inplace=True)
pref_data
```

	Regional	Province	District	Sub-District	Gender	Age	Age Range	Relation	Marriage	Registration	Substance Use	Aggression	Relationship Issues	Health Issues	Financial Issues
0	1	2	207	247	2	61.0	วัยสูงอายุ 60 ปีขึ้นไป	โสด	ไม่ระบุ	0	1	0	0	0	
1	1	2	193	155	2	26.0	วัยใหม่และเด็ก 19 - 35 ปี	โสด	ไม่ระบุ	0	1	0	0	0	
2	1	2	184	275	2	55.0	วัยกลางคน 36 - 59 ปี	โสด	ไม่ระบุ	0	0	0	1	0	
3	1	2	189	249	2	64.0	วัยสูงอายุ 60 ปีขึ้นไป	แยกกันอยู่	จะแต่งงานแต่	0	2	0	1	0	
4	1	2	194	46	1	33.0	วัยใหม่และเด็ก 19 - 35 ปี	สมรส	ยังไม่ได้แต่งงานแต่ยังคงอยู่	1	1	1	0	0	
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	
560	4	48	255	225	1	47.0	วัยกลางคน 36 - 59 ปี	สมรส	ยังไม่ได้แต่งงานแต่ยังคงอยู่	1	0	0	0	0	
561	4	56	135	69	1	39.0	วัยกลางคน 36 - 59 ปี	แยกกันอยู่	ยังไม่ได้แต่งงานแต่ยังคงอยู่	1	0	1	0	0	
562	4	56	263	230	1	40.0	วัยกลางคน 36 - 59 ปี	แยกกันอยู่	จะแต่งงานแต่	2	0	1	0	0	
563	4	56	3	95	1	64.0	วัยสูงอายุ 60 ปีขึ้นไป	สมรส	ยังไม่ได้แต่งงานแต่ยังคงอยู่	2	1	0	0	0	
564	0	0	0	0	0	NaN	NaN	NaN	NaN	389	315	134	109	86	

565 rows × 14 columns

ปัจจัยที่มีความหมายใกล้เคียงกันหรือเกี่ยวข้องซึ่งกันและกัน ได้ถูกจัดกลุ่มเข้าด้วยกันเป็นประเภทเดียวกัน วิธีนี้ช่วยลดจำนวนตัวแปรที่ต้องวิเคราะห์ และทำให้เห็นความสัมพันธ์ระหว่างปัจจัยต่างๆ ได้ชัดเจนยิ่งขึ้น

จากราฟแสดงข้อมูลให้เห็นว่า

- column Drug กับ column Alcohol รวมกันเป็น column Substance Use
- column authoritative กับ column Rage รวมกันเป็น column Aggression
- column Jealous กับ column Divorce รวมกันเป็น column Relationship Issue
- column Health กับ column Mental รวมกันเป็น column Health Issue
- column Gambling กับ column Economic stress รวมกันเป็น column Financial Issue

#### 3.2 แบ่งช่วงอายุของข้อมูล

ข้อมูลอายุเดิมที่อาจเป็นค่าต่อเนื่อง ได้ถูกแบ่งออกเป็นช่วงอายุที่เหมาะสม เพื่อให้เห็นภาพรวมของกลุ่มอายุต่างๆ ได้ชัดเจนยิ่งขึ้น การแบ่งช่วงอายุนี้ช่วยลดความซับซ้อนของข้อมูลและทำให้การวิเคราะห์ง่ายขึ้น

- วัยเด็กต่อนกลาง 7 - 12 ปี
  - วัยรุ่น 13 - 18 ปี
  - วัยผู้ใหญ่ต่อนตน 19 - 35 ปี
  - วัยกลางคน 36 - 59 ปี
  - วัยสูงอายุตั้งแต่ 60 ปีขึ้นไป

### 3.3 นำปัจจัยที่ไม่ได้ใช้ในการวิเคราะห์ออกจากการข้อมูล

## ประกอบด้วย Province, District, Sub-District

### 3.4 การแปลงข้อมูลเชิงคุณภาพเป็นเชิงปริมาณ

ข้อมูลที่อยู่ในรูปแบบ "ใช่" หรือ "ไม่ใช่" ได้ถูกแปลงเป็นเลข 0 และ 1 เพื่อให้สามารถนำไปวิเคราะห์ทางสถิติได้ร่างขึ้น

### (ກາພ່າດຂໍ້ມູນ Before Data Preparation)

ID	Regional	Age	Age Range_ໃຫຍ່ເຊົາຕົວໆ 7 - 12 ປີ	Age Range_ໃຫຍ່ເຊົາຕົວໆ 13 - 18 ປີ	Age Range_ໃຫຍ່ເຊົາຕົວໆ 19 - 35 ປີ	Age Range_ໃຫຍ່ເຊົາຕົວໆ 36 - 59 ປີ	Age Range_ໃຫຍ່ເຊົາຕົວໆ 60 ປີອັນປີ	Relation_ຂະໜາດ	Relation_Ice	Substance Use	Aggression	Relationship Issues	Health Issues	Financial Issues
0	ເກມນະຄ	61	0	0	0	0	1	0	1	0	1	0	0	0
1	ເກມນະຄ	26	0	0	1	0	0	0	1	0	0	0	1	0
2	ເກມນະຄ	55	0	0	0	1	0	0	1	0	0	0	1	0
3	ເກມນະຄ	64	0	0	0	0	1	1	0	0	2	0	1	0
4	ເກມນະຄ	33	0	0	1	0	0	0	0	1	1	1	0	0
5	ເກມນະຄ	36	0	0	0	1	0	0	1	0	0	1	0	0
6	ເກມນະຄ	40	0	0	0	1	0	0	0	1	0	1	0	0
7	ເກມນະຄ	42	0	0	0	1	0	0	0	1	1	0	0	0
8	ເກມນະຄ	18	0	0	1	0	0	0	0	1	1	0	0	0
9	ເກມນະຄ	33	0	0	0	1	0	0	0	0	1	0	0	0
10	ເກມນະຄ	22	0	0	0	1	0	0	1	0	0	1	0	0
11	ເກມນະຄ	68	0	0	0	1	0	0	0	0	0	0	1	0
12	ເກມນະຄ	36	0	0	0	1	0	0	1	1	0	0	0	0
13	ເກມນະຄ	40	0	0	0	1	0	0	0	1	0	0	0	0
14	ເກມນະຄ	48	0	0	0	1	0	0	0	1	1	1	0	0
15	ເກມນະຄ	27	0	0	1	0	0	0	0	1	0	1	0	0
16	ເກມນະຄ	39	0	0	0	1	0	0	0	1	1	0	0	0
17	ເກມນະຄ	23	0	0	0	1	0	0	1	1	0	0	0	0
18	ເກມນະຄ	30	0	0	0	1	0	0	0	2	0	1	0	0
19	ເກມນະຄ	52	0	0	0	1	0	0	0	0	0	0	1	1
20	ເກມນະຄ	56	0	0	0	1	0	0	1	0	1	0	0	0
21	ເກມນະຄ	39	0	0	0	1	0	0	1	0	1	0	0	0
22	ເກມນະຄ	45	0	0	0	1	0	0	0	1	0	0	0	1
23	ເກມນະຄ	45	0	0	0	1	0	0	0	1	0	0	0	0
24	ເກມນະຄ	44	0	0	0	1	0	0	0	0	0	0	1	0
25	ເກມນະຄ	48	0	0	0	1	0	0	0	0	1	0	0	0
26	ເກມນະຄ	50	0	0	0	1	0	0	0	0	1	0	0	0
27	ເກມນະຄ	58	0	0	0	1	0	0	0	1	0	0	1	0
28	ເກມນະຄ	48	0	0	0	1	0	0	0	0	1	1	0	0
29	ເກມນະຄ	30	0	0	1	0	0	0	1	1	0	0	0	0
30	ເກມນະຄ	26	0	0	1	0	0	0	1	0	2	0	0	0
31	ເກມນະຄ	55	0	0	0	1	0	0	1	0	0	1	0	0
32	ເກມນະຄ	60	0	0	0	1	0	0	0	0	0	1	0	0
33	ເກມນະຄ	44	0	0	0	1	0	0	0	0	1	0	0	0
34	ເກມນະຄ	33	0	0	0	1	0	0	0	0	1	0	0	0
35	ເກມນະຄ	32	0	0	0	1	0	0	0	0	1	0	0	0
36	ເກມນະຄ	68	0	0	0	1	0	0	1	0	0	1	0	0
37	ເກມນະຄ	25	0	0	0	1	0	0	0	1	0	1	0	0
38	ເກມນະຄ	61	0	0	0	1	0	0	1	0	0	1	0	0
39	ເກມນະຄ	30	0	0	0	1	0	0	1	0	0	1	0	0
40	ເກມນະຄ	53	0	0	0	1	0	0	1	1	0	0	0	1
41	ເກມນະຄ	24	0	0	0	1	0	0	0	1	0	0	0	0
42	ເກມນະຄ	37	0	0	0	1	0	0	0	0	0	0	0	1
43	ເກມນະຄ	43	0	0	0	1	0	0	0	0	1	0	0	0
44	ເກມນະຄ	31	0	0	0	1	0	0	0	1	1	2	0	0
45	ເກມນະຄ	29	0	0	0	1	0	0	0	1	0	1	0	0

(ກາພໍາດີຂໍ້ມູນ After Data Preparation)

## 4. Modeling

### 4.1

```
pref_models = setup(
    data=pref_data,
    session_id=123,
    ignore_features=['Province', 'District', 'Sub-District', 'Gender', 'Age Range', 'Relation', 'Mariage Registration']
)
```

	Description	Value
0	Session id	123
1	Original data shape	(564, 14)
2	Transformed data shape	(564, 7)
3	Ignore features	7
4	Numeric features	7
5	Preprocess	True
6	Imputation type	simple
7	Numeric imputation	mean
8	Categorical imputation	mode
9	CPU Jobs	-1
10	Use GPU	False
11	Log Experiment	False
12	Experiment Name	cluster-default-name
13	USI	a2c2

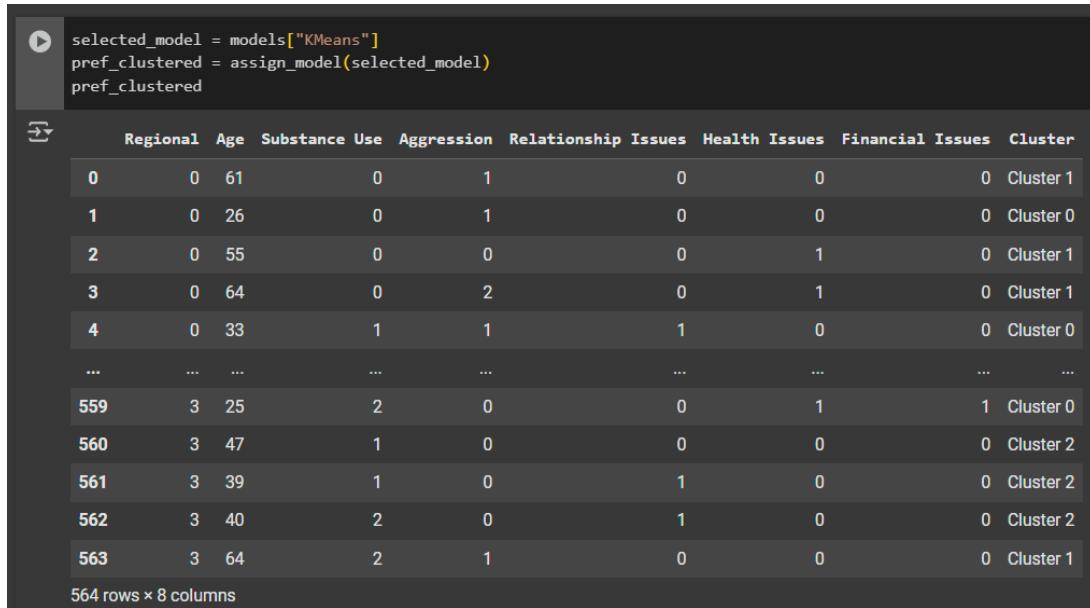
### 4.2

```
[ ] models = {
    "KMeans": create_model('kmeans', num_clusters=3),
    "DBSCAN": create_model('dbscan'),
    "Hierarchical": create_model('hclust')
}
```

	Silhouette	Calinski-Harabasz	Davies-Bouldin	Homogeneity	Rand Index	Completeness
0	0.4982	1203.8465	0.6161	0	0	0
	Silhouette	Calinski-Harabasz	Davies-Bouldin	Homogeneity	Rand Index	Completeness
0	0	0	0	0	0	0
	Silhouette	Calinski-Harabasz	Davies-Bouldin	Homogeneity	Rand Index	Completeness
0	0.4244	1096.5299	0.6385	0	0	0

## 5. Evaluation

### 5.1



The screenshot shows a Jupyter Notebook cell with the following content:

```
selected_model = models["KMeans"]
pref_clustered = assign_model(selected_model)
pref_clustered
```

Below the code, a Pandas DataFrame is displayed with the following structure:

	Regional	Age	Substance Use	Aggression	Relationship Issues	Health Issues	Financial Issues	Cluster
0	0	61	0	1	0	0	0	0 Cluster 1
1	0	26	0	1	0	0	0	0 Cluster 0
2	0	55	0	0	0	1	0	0 Cluster 1
3	0	64	0	2	0	1	0	0 Cluster 1
4	0	33	1	1	1	0	0	0 Cluster 0
...	...	...	...	...	...	...	...	...
559	3	25	2	0	0	1	1	1 Cluster 0
560	3	47	1	0	0	0	0	0 Cluster 2
561	3	39	1	0	1	0	0	0 Cluster 2
562	3	40	2	0	1	0	0	0 Cluster 2
563	3	64	2	1	0	0	0	0 Cluster 1

564 rows × 8 columns

## 6. Deployment

### 6.1 บันทึกโมเดลที่ต้องการนำไปใช้

```
save_model(final_model, 'final_cluster_model')

Transformation Pipeline and Model Successfully Saved
(Pipeline(memory=Memory(location=None),
steps=[('numerical_imputer',
TransformerWrapper(include=['Regional', 'Age', 'Substance Use',
'Aggression',
'Relationship Issues',
'Health Issues',
'Financial Issues'],
transformer=SimpleImputer())),
('categorical_imputer',
TransformerWrapper(include=[], transformer=SimpleImputer(strategy='most_frequent'))),
('trained_model',
    Regional   Age  Substance Use  Aggression  Relationship Issues \
0          0    61            0           1              0
1          0    26            0           1              0
2          0    55            0           0              0
3          0    64            0           2              0
4          0    33            1           1              1
..        ...
559         3    25            2           0              0
560         3    47            1           0              0
561         3    39            1           0              1
562         3    40            2           0              1
563         3    64            2           1              0

   Health Issues  Financial Issues  Cluster
0             0            0  Cluster 1
1             0            0  Cluster 0
2             1            0  Cluster 1
3             1            0  Cluster 1
4             0            0  Cluster 0
..        ...
559            1            1  Cluster 0
560            0            0  Cluster 2
561            0            0  Cluster 2
562            0            0  Cluster 2
563            0            0  Cluster 1

[564 rows x 8 columns]]),
'final_cluster_model.pkl')
```

### 6.2 นำเข้า library ที่จำเป็นในการใช้งาน

```
%%writefile test.py
import streamlit as st
import pandas as pd
import numpy as np
import json
import joblib
from sklearn.cluster import AgglomerativeClustering
from sklearn.metrics.pairwise import euclidean_distances
```

- Streamlit เป็น library ของ Python ที่ใช้สำหรับสร้างเว็บแอปพลิเคชันสำหรับ Machine Learning และ Data Science ได้อย่างรวดเร็วและง่ายดาย
- Pandas เป็น library ที่ใช้สำหรับการจัดการและวิเคราะห์ข้อมูลที่มีโครงสร้าง เช่น ตาราง (DataFrames)
- NumPy เป็น library ที่ใช้สำหรับการคำนวณทางคณิตศาสตร์และวิทยาศาสตร์ โดยเฉพาะการจัดการกับอาร์เรย์ (Arrays)

- json เป็น library ที่ใช้ในการทำงานกับข้อมูลในรูปแบบ JSON (JavaScript Object Notation) ซึ่งเป็นรูปแบบข้อมูลที่นิยมใช้ในการแลกเปลี่ยนข้อมูลระหว่างแอปพลิเคชัน
- joblib เป็น library ที่ใช้สำหรับการบันทึกและโหลดโมเดล Machine Learning เพื่อนำไปใช้งานในภายหลัง
- from sklearn.cluster import AgglomerativeClustering เป็นการนำเข้าคลาส AgglomerativeClustering จาก module cluster ของ sklearn ซึ่งเป็นอัลกอริทึมที่ใช้สำหรับการจัดกลุ่มข้อมูลแบบ Hierarchical Clustering.
- from sklearn.metrics.pairwise import euclidean\_distances เป็นการนำเข้าฟังก์ชัน euclidean\_distances ซึ่งใช้สำหรับคำนวณระยะห่างแบบยุคลิด (Euclidean distance) ระหว่างจุดข้อมูล

### 6.3

```
# โหลดข้อมูลจาก CSV และลบคอลัมน์ที่ไม่ต้องการ ("dtype", "Regional")
try:
    final_cluster_data = pd.read_csv("/content/sample_data/pref_data.csv")
    final_cluster_data = final_cluster_data.drop(columns=["dtype", "Regional"], errors="ignore")
    st.sidebar.success("Successfully loaded clustering data from /content/sample_data/pref_data.csv")

    st.sidebar.info(f"Data shape: {final_cluster_data.shape}")
    if 'Cluster' in final_cluster_data.columns:
        st.sidebar.info(f"Found {final_cluster_data['Cluster'].nunique()} clusters in the data")
except Exception as e:
    st.sidebar.error(f"Error loading CSV data: {e}")
    st.stop()
```

### 6.4

```
# โหลดข้อมูลภูมิภาค
try:
    with open("/content/sample_data/region_province_district_subdistrict.json", "r", encoding="utf-8") as f:
        region_data = json.load(f)
    st.sidebar.success("Successfully loaded region data")
except Exception as e:
    st.sidebar.error(f"Error loading region data: {e}")
    st.stop()
```

### 6.5

```

# โหลด label encoders (หากใช้งาน)
try:
    les = joblib.load("/content/les.pkl")
    st.sidebar.success("Successfully loaded label encoders")
except Exception as e:
    st.sidebar.error(f"Error loading label encoders: {e}")
    st.stop()

```

## 6.6 ออกแบบแบบฟอร์มการนำเข้าข้อมูลและประมวลผลคำตอบ

```

try:
    # ระบุคอลัมน์ที่ไม่ต้องการ clustering
    irrelevant_cols = ['Province', 'District', 'Sub-District', 'Gender', 'Age Range', 'Relation', 'Marriage Registration']

    # เติบอกรายชื่อคอลัมน์ "Cluster", "Regional" และคอลัมน์ที่นับผลการ clustering
    input_for_clustering = pd.DataFrame()

    for col in ref_cols:
        if col in ['Cluster', 'Regional'] or col in irrelevant_cols:
            continue
        if col in new_df.columns:
            input_for_clustering[col] = new_df[col]
        else:
            input_for_clustering[col] = 0

    st.write("|||| ❸ นำเข้าข้อมูลที่ใช้ในการวิเคราะห์ (เฉพาะปีจ蛾ร์ที่มีผล):")
    st.dataframe(input_for_clustering)

    # ค่าพารามิเตอร์ที่ใช้สำหรับการวิเคราะห์
    feature_cols = input_for_clustering.columns.tolist()
    if not feature_cols:
        st.error("ไม่มีคอลัมน์ที่สามารถวิเคราะห์ได้")
        st.stop()

    reference_features = final_cluster_data[feature_cols]
    input_features = input_for_clustering[feature_cols]

    # st.write("|||| ❹ ผลลัพธ์ที่ได้สำหรับการวิเคราะห์:")
    # st.write(", ".join(feature_cols))

    # คำนวณระยะห่างแบบ Euclidean
    distances = euclidean_distances(input_features, reference_features)
    most_similar_idx = np.argmin(distances[0])

    # ตั้งค่า Cluster จากค่าของอัลกอริทึม (ค่าพารามิเตอร์ Cluster)
    if 'Cluster' in final_cluster_data.columns:
        assigned_cluster = final_cluster_data.iloc[most_similar_idx]['Cluster']
        # หาก assigned_cluster เป็นสตริงที่ "Cluster" มาก็ ให้ตัดออก
        if isinstance(assigned_cluster, str) and assigned_cluster.startswith("Cluster"):
            try:
                assigned_cluster = int(assigned_cluster.replace("Cluster", "").strip())
            except Exception as e:
                st.error(f"ไม่สามารถแปลงค่า cluster ได้: {e}")
                st.stop()
        else:
            combined_data = pd.concat([reference_features, input_features], ignore_index=True)
            model = AgglomerativeClustering(n_clusters=3)
            clusters = model.fit_predict(combined_data)
            assigned_cluster = clusters[-1]

    st.subheader(f"➔ คุณอยู่ในกลุ่มที่: **Cluster {assigned_cluster}**")
    st.write(f"ระยะทางจากกลุ่มอื่นที่ใกล้เคียงที่สุด: {distances[0][most_similar_idx]:.2f} -")

```

```

st.subheader("**** 📈 គណនីកម្លែងក្នុងក្រុមពេទ្យ: **Cluster {assigned_cluster}**")
st.write(f"នាមខ្លួនបានចូលរួមជាក្នុងក្រុមទី {distances[0][most_similar_idx]:.2f}")


st.write("**** 📈 ស័ក្រមនៃក្នុម:")
if int(assigned_cluster) == 0:
    st.info("ក្នុមទី 0: ក្នុមដែលគឺជាការមេដែរគោរះ")
elif int(assigned_cluster) == 1:
    st.warning("ក្នុមទី 1: ក្នុមដែលគឺជាការមេដែរបានគោរះ")
elif int(assigned_cluster) == 2:
    st.error("ក្នុមទី 2: ក្នុមដែលគឺជាការមេដែរសុំង")
else:
    st.info(f"Cluster {assigned_cluster}: នៅមីន់អ្នកបានពិនិត្យសារបែនក្នុមនេះ")

# ផែតង់អ្នកបានចូលរួមជាក្នុងក្នុមទី 0 ទាំង Cluster ទាំង 3
st.write("**** 📈 អ្នកបានចូលរួមជាក្នុងក្នុមទី 0 ទាំង 3 គ្នុម:")
similar_data = final_cluster_data.iloc[[most_similar_idx]].to_frame().T
st.dataframe(similar_data)

except Exception as e:
    st.error(f"**** 📈 កំណត់ថាបានរកឃើញការបញ្ហាសម្រាប់ក្នុមទី 0: {e}")
    st.info("នាមខ្លួនបានចូលរួមជាក្នុងក្នុមទី 0")
    import traceback
    st.code(traceback.format_exc())
    st.write("**** 📈 តើវាបានចូលរួមជាក្នុងក្នុមទី 0 ទាំង 3 គ្នុម?")
    st.dataframe(final_cluster_data.head())

```

## 6.7 ตัวอย่างแบบฟอร์ม

#### 6.7.1 กรอกข้อมูล ภูมิภาค/จังหวัด/อำเภอ/ตำบล



### 6.7.2 กรอกข้อมูล อายุ/ข้อมูลจดการทะเบียน/ปัจจัยที่เกิดขึ้น

อายุ  
25

Mariage Registration  
 ไม่ได้  
 จดทะเบียน

Relation  
 โสด  
 สมรส  
 หย่าร้าง

Substance Use (ตัวมากกว่า 0 จะถูกเปลี่ยนเป็น 1)  
0

Aggression (ตัวมากกว่า 0 จะถูกเปลี่ยนเป็น 1)  
0

Relationship Issues (ตัวมากกว่า 0 จะถูกเปลี่ยนเป็น 1)  
1

Health Issues (ตัวมากกว่า 0 จะถูกเปลี่ยนเป็น 1)  
0

Financial Issues (ตัวมากกว่า 0 จะถูกเปลี่ยนเป็น 1)  
0

Predict Cluster

### 6.7.3 แสดงข้อมูลที่กรอก/ข้อมูลที่ใช้เคราะห์/ลักษณะของกลุ่ม/ข้อมูลอ้างอิง

Predict Cluster

ข้อมูลที่กรอก:

	Region	Province	District	Sub-District	Age	Mariage Registration
0	ภาคกลาง	กรุงเทพมหานคร	เขตหนองจอก	หนองจอก	25	0

ข้อมูลที่ใช้ในการวิเคราะห์ (เฉพาะฟีเจอร์ที่มีผล):

	Age	Substance Use	Aggression	Relationship Issues	Health Issues	Financial Issues
0	25	0	0	1	0	0

คุณถูกจัดอยู่ในกลุ่มที่: Cluster 0  
ระยะห่างจากกลุ่มอ้างอิงใกล้เคียงที่สุด: 0.00

ลักษณะของกลุ่ม:

Cluster 0: กลุ่มที่มีความเสี่ยงต่อ

ข้อมูลอ้างอิงที่ใกล้เคียงที่สุด:

	Age	Substance Use	Aggression	Relationship Issues	Health Issues	Financial Issues
372	25	0	0	1	0	0

## เอกสารอ้างอิง

Dataset : <https://data.go.th/dataset/gdpublish-dwf-pb-dmv01-050507-04>

Business Understanding: <https://rsucon.rsu.ac.th/files/proceedings/nation2019/NA19-136.pdf>

[https://www.m-society.go.th/ewtadmin/ewt/mso\\_web/download/article/article\\_20150206144414.pdf](https://www.m-society.go.th/ewtadmin/ewt/mso_web/download/article/article_20150206144414.pdf)

Modeling: <https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html>

เอกสารประกอบการเรียน:

[https://colab.research.google.com/drive/1H\\_xg12m0jeJDgqEe99QqTu26MaQ5g-52?authuser=1&usp=classroom\\_web#scrollTo=7JLDYx\\_mu7Ss](https://colab.research.google.com/drive/1H_xg12m0jeJDgqEe99QqTu26MaQ5g-52?authuser=1&usp=classroom_web#scrollTo=7JLDYx_mu7Ss)